Modelo de Golos Esperados para Bolas Paradas no Futebol

Guia de Utilização

Aplicação a Novos Dados e Adaptação de Outras Fontes

Índice

1. Para que serve a ferramenta....3
O que pode ser avaliado....3
Percurso recomendado....3
Como consultar o guia....3
2. Ficheiros necessários....4
3. Preparar o computador....4
Windows com PowerShell....4
macOS ou Linux....4
O que preparar antes da primeira execução....5
4. Dados de entrada obrigatórios....5
5. Coordenadas e posições dos jogadores....6
Localização do remate....6
Formato de shot_freeze_frame....6
6. Adaptar dados de outra fonte....7
Transformar as coordenadas....7
Harmonizar as categorias....7
Identificar a primeira fase e obter as posições....7
7. Dicionário das variáveis construídas....7
Regras geométricas que devem ser preservadas....9
As 15 variáveis efetivamente selecionadas....9
8. Aplicar o modelo a novos dados....9
Opção recomendada com CSV....9
Alternativa em Python....10
9. Confirmar e interpretar a saída....10
Verificações simples após a execução....11
Como usar na análise de futebol....11
Registar a aplicação....11
10. Problemas frequentes....11
Valores em falta e posições incompletas....12
11. O que foi analisado e concluído....12
Percurso da análise no notebook....12
Resultados no teste....13
O que os resultados permitem concluir....13
Limites para a utilização....13

1. Para que serve a ferramenta

Este guia explica como atribuir uma probabilidade de golo a novos remates utilizando o modelo já treinado. Destina-se a analistas, treinadores e outros utilizadores que pretendam aplicar a ferramenta sem repetir a análise ou o treino. A execução atual requer Python e uma linha de comandos; não existe uma aplicação gráfica. A instalação inicial e a adaptação de dados de outro fornecedor podem exigir apoio técnico.

O que pode ser avaliado

A versão atual avalia apenas remates da primeira fase de posses iniciadas por cantos ou livres indiretos. Não abrange penáltis, livres diretos, cantos diretos, lançamentos laterais ou remates de segunda fase. A ferramenta usa as etiquetas fornecidas nos dados e não identifica autonomamente a sequência de bola parada.

O resultado chama-se shot_set_piece_xg. Um valor de 0,10 significa uma probabilidade estimada de golo de 10%. A soma dos valores resume os golos esperados das oportunidades avaliadas. Um remate com xG elevado pode falhar e um remate com xG reduzido pode resultar em golo; o valor não garante um desfecho.

Percurso recomendado

1. Preparar um CSV com as 15 colunas obrigatórias e confirmar a elegibilidade dos remates.

2. Instalar o ambiente uma vez e manter juntos os ficheiros do projeto.

3. Executar o comando de aplicação do modelo e abrir o CSV de saída.

4. Confirmar o número de remates avaliados e interpretar os valores entre 0 e 1.

5. Se os dados forem de outra fonte, cumprir primeiro as regras de adaptação deste guia.

Como consultar o guia

Tema	Secção
Ficheiros e instalação	2 e 3
Dados obrigatórios e posições dos jogadores	4 e 5
Outra fonte e dicionário das variáveis	6 e 7
Aplicar o modelo e interpretar a saída	8 e 9
Resolver problemas	10
Análise e conclusões do notebook	11

2. Ficheiros necessários

Ficheiro ou pasta	Função e utilização
script.py	Aplica o modelo a um CSV ou a uma tabela em Python. É o ponto de entrada para o uso corrente.
models/pipeline.joblib	Modelo já treinado, incluindo o pré-processamento, a seleção fixa de variáveis e o classificador.
utils/	Contém as funções de preparação, geometria e análise. Deve permanecer junto do script, sem alterar a estrutura.
requirements.txt	Versões das dependências do ambiente de desenvolvimento. Usado na instalação.
README.md	Referência técnica sobre instalação, entrada, execução e limitações.
notebook.ipynb	Explica a exploração, preparação, seleção, avaliação e interpretação. Não é necessário executá-lo para avaliar novos dados.
data/	Local sugerido para colocar o CSV de entrada e guardar o de saída.
temp/model_search_checkpoint.pkl.gz	Resultados intermédios da pesquisa de modelos. Não é necessário para aplicar o modelo exportado.

Extraia primeiro o ZIP. A pasta principal é aquela onde se encontram script.py, requirements.txt, models e utils. Todos os comandos deste guia são executados nessa pasta, com os caminhos relativos apresentados. Os nomes new_events.csv e new_events_with_set_piece_xg.csv são exemplos e podem ser substituídos pelos nomes escolhidos pelo utilizador.

Mantenha a pasta do projeto intacta. O modelo recebe variáveis construídas pelas funções em utils; copiar apenas pipeline.joblib para uma pasta vazia não permite executar o comando apresentado. Para novas previsões, não é necessário voltar a treinar nem exportar o modelo.

3. Preparar o computador

O projeto foi desenvolvido com Python 3.12.6. Instale essa versão e abra um terminal na pasta principal. No Windows, pode abrir a pasta no Explorador e usar a opção para abrir um terminal. Em macOS ou Linux, abra o Terminal e navegue para a pasta com cd. As ferramentas abaixo selecionam um Python já instalado; não o instalam.

Windows com PowerShell

```
py -3.12 -m venv .venv
.\.venv\Scripts\Activate.ps1
python --version
python -m pip install -r requirements.txt
```

macOS ou Linux

```
python3.12 -m venv .venv
source .venv/bin/activate
python --version
python -m pip install -r requirements.txt
```

O comando de versão deve indicar Python 3.12.6. A pasta .venv é um ambiente separado para instalar as dependências do projeto. A instalação é feita uma vez; em utilizações posteriores, abra o terminal na mesma pasta e ative novamente o ambiente com o comando correspondente ao seu sistema.

A lista requirements.txt reflete o ambiente de desenvolvimento e inclui dependências indiretas. Se a instalação falhar no seu sistema, peça apoio para resolver a compatibilidade mantendo as versões do modelo e das bibliotecas identificadas. Se o PowerShell bloquear a ativação, pode executar diretamente .\.venv\Scripts\python.exe em vez de python, sem alterar políticas do computador.

O que preparar antes da primeira execução

Tenha o CSV de entrada em data/new_events.csv e confirme que models/pipeline.joblib existe. São necessários dados de eventos já organizados em colunas. Um ficheiro JSON bruto da StatsBomb, com objetos aninhados ao nível do evento, não pode ser passado diretamente ao comando de CSV. O formato tabular deve corresponder ao descrito nas secções seguintes.

4. Dados de entrada obrigatórios

A entrada é um CSV com uma linha por evento e os nomes exatos das colunas abaixo. Pode incluir todos os eventos ou apenas remates, desde que as 15 colunas existam. A ordem das colunas é livre e podem existir colunas adicionais. Não são necessários o resultado do remate, shot_outcome, nem o xG da StatsBomb, shot_statsbomb_xg. Estes campos só seriam úteis para avaliar posteriormente o desempenho.

Coluna	Significado e valores para remates elegíveis
type	Tipo de evento. Usar Shot.
play_pattern	Origem da posse: From Corner ou From Free Kick.
shot_type	Usar Open Play para a finalização no decorrer da rotina. Não usar Free Kick para um remate indireto.
set_piece_phase	Fase numérica 1. A ferramenta não calcula esta etiqueta.
location	Lista [x, y, z] ou [x, y], no sistema 120 × 80; ver secção 5.
under_pressure	Rematador sob pressão: True ou False.
shot_first_time	Remate de primeira: True ou False.
shot_one_on_one	Situação de um para um: True ou False.
shot_open_goal	Remate para baliza aberta: True ou False.
shot_follows_dribble	Remate após drible: True ou False.
shot_aerial_won	Remate associado a duelo aéreo ganho: True ou False.
shot_freeze_frame	Lista dos jogadores observados no instante do remate, com posições e equipa relativa; ver secção 5.
shot_body_part	Head, Left Foot, Right Foot ou Other.
shot_technique	Normal, Volley, Half Volley ou Other. Outras técnicas são agrupadas em Other.

Coluna	Significado e valores para remates elegíveis
shot_key_pass_id	Identificador do passe-chave associado, ou valor em falta se não existir. Não se deve preencher artificialmente.

Maiúsculas, espaços e grafia devem ser respeitados. Por exemplo, Shot e shot não são equivalentes. From Free Kick identifica a origem da posse; Open Play identifica o tipo de finalização. Um evento recebe xG apenas quando satisfaz simultaneamente as quatro condições de type, play_pattern, shot_type e set_piece_phase.

5. Coordenadas e posições dos jogadores

Localização do remate

Use x entre 0 e 120 e y entre 0 e 80, com o ataque orientado para a baliza em x=120 e o centro dessa baliza em y=40. As posições de todos os jogadores devem usar o mesmo referencial e o mesmo instante do remate. Estes são limites de preparação dos dados; o script não verifica integralmente os intervalos. Não envie coordenadas já convertidas para metros: a ferramenta realiza essa conversão internamente.

A localização [110, 40, 1.8] representa um remate próximo do centro da baliza, com altura de 1,8 metros. Em campos estruturados, os números decimais são escritos com ponto. O terceiro valor, z, representa a altura do remate: preserve a unidade de altura da fonte StatsBomb, em metros, sem a multiplicar pelas escalas horizontais. Se apenas [x, y] for fornecido, o script atribui z=0. Não existe um limite superior de altura validado pelo script.

Formato de shot_freeze_frame

Cada jogador é um objeto com location, teammate e position. teammate é True para um colega do rematador e False para um adversário. O guarda-redes adversário é identificado por position com id igual a 1; o nome da posição, por si só, não basta. Não inclua o rematador como seu próprio colega, pois isso introduziria uma distância artificial de zero.

```
[
  {"location": [118, 40], "teammate": false,
   "position": {"id": 1}},
  {"location": [109, 39], "teammate": false,
   "position": {"id": 3}},
  {"location": [108, 44], "teammate": true,
   "position": {"id": 23}}
]
```

O exemplo ilustra apenas a estrutura; não representa uma cobertura espacial suficiente para avaliar um remate real. Inclua todos os jogadores observados de acordo com a cobertura disponível. Sem a identificação correta do guarda-redes, este pode ser contado como defesa de campo. Jogadores sem uma localização válida são ignorados.

Em Python, usam-se True e False; em JSON, true e false. location e shot_freeze_frame podem ser listas reais em Python ou texto com listas e objetos em formato JSON ou literal Python. Ao guardar em CSV, estes campos devem permanecer numa única célula, com aspas escapadas corretamente. É preferível exportar o CSV com pandas a escrevê-lo manualmente.

6. Adaptar dados de outra fonte

A opção recomendada é transformar os dados da outra fonte nas 15 colunas de entrada e deixar o script construir as variáveis. Não basta renomear colunas: é necessário reproduzir o significado das etiquetas, a orientação das coordenadas e a informação espacial. A compatibilidade de formato não garante que o modelo tenha o mesmo desempenho noutra fonte ou competição.

Transformar as coordenadas

Se a fonte usa coordenadas horizontais de 0 a L e verticais de 0 a W, na mesma orientação, converta x para 120 × x/L e y para 80 × y/W. Se a origem estiver no centro, transladar primeiro para intervalos iniciados em zero. Se o ataque estiver orientado para o lado oposto, uma rotação de 180 graus no sistema já convertido corresponde a x novo = 120 − x e y novo = 80 − y. A transformação deve ser aplicada ao rematador e a todos os jogadores. Verifique ainda o sentido do eixo vertical da fonte antes de escolher a transformação.

Harmonizar as categorias

Mapeie os rótulos da fonte para as categorias exatas da secção 4. Head significa cabeça; Left Foot, pé esquerdo; Right Foot, pé direito; Other, outra parte do corpo. Normal representa técnica normal; Volley, vólei; Half Volley, meio-vólei. Técnicas como calcanhar ou pontapé de bicicleta entram em Other. Categorias desconhecidas da parte do corpo devem ser harmonizadas explicitamente para Other: o script não converte automaticamente todos os rótulos desconhecidos dessa coluna.

Represente os seis indicadores contextuais com True ou False. O script também reconhece 1 e as cadeias 1, true, True e TRUE como verdadeiras; outros valores não omissos são tratados como falsos. Não use Sim ou Não sem conversão prévia. Um passe-chave identificado torna o remate assistido; sem passe, use um valor realmente em falta, não uma cadeia vazia criada manualmente nem um identificador fictício.

Identificar a primeira fase e obter as posições

Reproduza o conceito de primeira fase a partir das sequências da fonte, tendo em conta alterações após remates e alívios. Reveja desvios, ressaltos e remates após livres diretos falhados, pois a classificação original tem limitações nestas situações. Não atribua fase 1 a todos os remates só para obter previsões.

Se a fonte não disponibilizar posições dos jogadores no instante do remate, os dados de eventos, por si só, não permitem reconstruir todas as variáveis necessárias. A ausência de jogadores não deve ser simulada com uma lista vazia. Obtenha informação espacial compatível ou desenvolva e valide um modelo com os dados efetivamente disponíveis. Não preencha distâncias ou ângulos com zeros para satisfazer o formato.

7. Dicionário das variáveis construídas

As 15 colunas de entrada são transformadas em 46 variáveis. A tabela seguinte apresenta todas, agrupando apenas nomes que partilham a mesma definição. Estas colunas são construídas automaticamente; não precisam de ser acrescentadas ao CSV. Os limites indicados são domínios lógicos ou geométricos, não os mínimos e máximos observados no treino, nem garantias de validação

pelo script. Não existe um intervalo universal de treino documentado para aceitar ou rejeitar novos remates.

Nas fórmulas seguintes, bola significa a localização do remate. As distâncias são horizontais, em metros, num campo assumido de 105 × 68 metros. Os ângulos são em radianos. Na geometria interna, a linha de baliza é x=105, o centro é (105, 34) e os postes são (105, 30,6) e (105, 37,4). Estes pontos resultam dos postes (120, 36) e (120, 44), produzindo largura de 6,8 metros. Preserve a convenção do modelo exportado; alterá-la exige reavaliação e poderá exigir novo treino.

Nomes exatos	**N**	**Definição**	**Domínio**
shot_body_part_Head; shot_body_part_Left Foot; shot_body_part_Other; shot_body_part_Right Foot	4	Indicadores da parte do corpo.	0 ou 1.
shot_technique_Half Volley; shot_technique_Normal; shot_technique_Other; shot_technique_Volley	4	Indicadores da técnica, após agregação.	0 ou 1.
under_pressure; shot_first_time; shot_one_on_one; shot_open_goal; shot_follows_dribble; shot_aerial_won	6	Indicadores contextuais da secção 4.	0 ou 1; omissos → 0.
shot_from_corner; shot_assisted	2	Origem em canto; existência de passe-chave.	0 ou 1.
x; y; z	3	Coordenadas originais e altura do remate.	x: 0–120; y: 0–80; z ≥ 0, sem máximo imposto.
shot_distance_to_goal; shot_distance_to_goal_center	2	Distância perpendicular à linha de baliza, |105 − x em metros|; distância euclidiana ao centro.	Metros ≥ 0. Não são duas distâncias equivalentes.
nearest_defender_1_distance; nearest_defender_2_distance; nearest_defender_3_distance	3	Distância ao 1.º, 2.º e 3.º adversário de campo mais próximo. Exclui o guarda-redes identificado.	Metros ≥ 0; NaN se não houver jogadores suficientes.
defenders_within_1m; defenders_within_3m; defenders_within_5m	3	Número de adversários de campo à distância ≤ 1, 3 e 5 m da bola.	Inteiros ≥ 0, até ao número de adversários de campo observados.
defenders_in_shot_triangle; closest_defender_in_shot_triangle; avg_distance_defenders_in_triangle	3	Número de defesas dentro ou na fronteira do triângulo bola–postes; menor distância e distância média desses defesas à bola.	Contagem ≥ 0; distâncias ≥ 0 m ou NaN se o triângulo não contiver defesas.
open_goal_angle; blocked_goal_angle; fraction_goal_angle_blocked	3	Ângulo total da baliza menos obstrução por defesas de campo; união angular obstruída; proporção obstruída. O guarda-redes é tratado separadamente.	Ângulos ≥ 0 e ≤ ângulo total; proporção 0–1 ou NaN se o ângulo total for zero.

Nomes exatos	N	Definição	Domínio
gk_distance_to_ball; gk_distance_to_goal; gk_distance_to_goal_center; gk_distance_to_shot_centerline; gk_lateral_position; gk_goal_angle_coverage	6	Distâncias do guarda-redes à bola, à linha de baliza, ao centro e à reta infinita bola–centro; desvio lateral face a y=34; ângulo da baliza coberto pelo guarda-redes.	Distâncias ≥ 0 m; desvio lateral com sinal (−34 a 34 m no campo); cobertura ≥ 0 e ≤ ângulo total. NaN se não identificado.
nearest_teammate_1_distance; nearest_teammate_2_distance; nearest_teammate_3_distance	3	Distâncias aos três colegas observados mais próximos, por ordem.	Metros ≥ 0; NaN se não houver colegas suficientes.
teammates_within_1m; teammates_within_3m; teammates_within_5m	3	Número de colegas à distância ≤ 1, 3 e 5 m da bola.	Inteiros ≥ 0, até ao número de colegas observados.
teammates_in_shot_triangle	1	Número de colegas dentro ou na fronteira do triângulo bola–postes.	Inteiro ≥ 0, até ao número de colegas observados.

Regras geométricas que devem ser preservadas

Para obstrução angular, os defesas são aproximados por círculos de raio 0,35 metros e o guarda-redes por um círculo de raio 0,50 metros. Os intervalos cobertos são limitados ao ângulo da baliza; a união evita contar duas vezes zonas sobrepostas. A contagem de jogadores próximos inclui a fronteira do raio. A altura z não entra nestas distâncias e ângulos, que são calculados em duas dimensões.

As 15 variáveis efetivamente selecionadas

O classificador final usa: shot_technique_Half Volley, shot_technique_Other, shot_first_time, shot_one_on_one, shot_open_goal, shot_aerial_won, shot_assisted, shot_distance_to_goal, shot_distance_to_goal_center, nearest_defender_2_distance, defenders_within_3m, defenders_within_5m, open_goal_angle, gk_distance_to_ball e gk_goal_angle_coverage.

Apesar desta seleção, a pipeline fornecida espera o esquema completo de 46 variáveis construídas. A interface de utilização continua, por isso, a exigir as 15 colunas de entrada, incluindo as que originam variáveis não retidas pelo classificador. Para outra fonte, use preferencialmente a adaptação das entradas. Passar apenas os 15 preditores selecionados diretamente à pipeline não corresponde à interface fornecida.

8. Aplicar o modelo a novos dados

Opção recomendada com CSV

1. Coloque o ficheiro preparado em data/new_events.csv. Guarde-o como CSV separado por vírgulas, com ponto nos números decimais e com os campos aninhados corretamente protegidos por aspas. A leitura padrão do script não está configurada para CSV separado por ponto e vírgula. Se a exportação vier do Excel com outro separador, converta-a antes ou use a opção Python abaixo.

2. Abra o terminal na pasta principal do projeto e ative o ambiente Python. Execute o comando numa única linha:

```
python script.py data/new_events.csv models/pipeline.joblib
data/new_events_with_set_piece_xg.csv
```

3. Aguarde a conclusão. O programa escreve o caminho do ficheiro produzido. Os três argumentos são, por ordem: CSV de entrada, modelo treinado e CSV de saída. O comando cria a pasta de saída, se necessário. Use nomes diferentes para entrada e saída para conservar os dados originais. Caminhos com espaços devem ser colocados entre aspas.

4. Abra data/new_events_with_set_piece_xg.csv e procure a nova coluna shot_set_piece_xg. Confirme os valores e a quantidade de remates avaliados conforme a secção 9. A ferramenta mantém as linhas originais e acrescenta a coluna; se esta já existir, os seus valores são substituídos.

Alternativa em Python

```
import pandas as pd
from script import add_set_piece_xg

events = pd.read_csv("data/new_events.csv")
scored = add_set_piece_xg(
    events, model="models/pipeline.joblib"
)
scored.to_csv(
    "data/new_events_with_set_piece_xg.csv", index=False
)
```

Para um CSV com separador de ponto e vírgula e decimais com vírgula, a leitura pode ser adaptada com pd.read_csv("data/new_events.csv", sep=";", decimal=","). Esta opção trata as colunas tabulares; dentro de location e shot_freeze_frame, os números devem continuar num formato JSON ou literal Python válido, com ponto decimal.

Na utilização em Python, o índice da tabela tem de ser único. A função devolve uma cópia por defeito, preservando os dados de entrada em memória. Não é necessário fornecer credenciais StatsBomb para avaliar um CSV já preparado; a recolha de novos dados diretamente ao fornecedor é um processo separado e depende do respetivo acesso.

9. Confirmar e interpretar a saída

Situação	Leitura correta
shot_set_piece_xg = 0.10	Probabilidade estimada de golo de 10% para esse remate.
Valor em branco no CSV ou NaN em Python	O evento não foi considerado elegível. Não equivale a xG zero.
Soma de xG = 1.40	As oportunidades avaliadas totalizam 1,40 golos esperados; o número real pode ser diferente.
Mesmo remate com valor diferente do exportado no notebook	O notebook inclui previsões fora da partição de ajuste; o modelo de aplicação foi ajustado à amostra completa. Não se espera igualdade exata.

Verificações simples após a execução

```
xg = scored["shot_set_piece_xg"]
print("Linhas de entrada:", len(events))
print("Linhas de saída:", len(scored))
print("Remates avaliados:", xg.notna().sum())
print("Total de xG:", xg.sum(min_count=1))
print("Valores válidos:", xg.dropna().between(0, 1).all())
```

Compare o número de remates avaliados com a contagem de eventos que satisfazem os quatro critérios de elegibilidade. Um total sem remates avaliados deve permanecer sem valor, em vez de ser interpretado como zero. Conserve identificadores de jogo e evento nas colunas adicionais para poder relacionar os resultados com as imagens e com a análise da equipa.

Como usar na análise de futebol

Pode comparar a qualidade média dos remates ou somar o xG de conjuntos comparáveis, indicando sempre o âmbito: primeira fase após cantos e livres indiretos. Para avaliar a eficácia de uma rotina, complemente com a frequência com que esta produz remate, pois o modelo não atribui valor a bolas paradas sem finalização. Não interprete os valores como medidas isoladas de qualidade do jogador.

Registar a aplicação

Guarde a data da aplicação, a origem dos dados, a competição, os critérios de inclusão e a versão dos ficheiros do modelo e de preparação utilizados. Mantenha a entrada e a saída identificáveis. Uma mudança de fornecedor, cobertura espacial ou definição de evento deve ser acompanhada de nova avaliação; obter um número sem erro não demonstra que o modelo esteja calibrado nesse contexto.

10. Problemas frequentes

Sinal ou mensagem	Causa provável e ação
Missing required StatsBomb columns	Falta uma ou mais das 15 colunas. Corrija os nomes e a exportação. A verificação também se aplica a ficheiros sem remates elegíveis.
Todos os resultados ficam vazios	Verifique as quatro condições de elegibilidade, maiúsculas e etiquetas. Fase em falta ou não numérica não é elegível.
Eligible shots have invalid locations	Há localização omissa ou sem uma lista de pelo menos dois valores. Corrija a posição; ambos os valores devem ser numéricos.
Could not parse location ou shot_freeze_frame	O texto não é JSON nem literal Python válido. Reveja aspas, vírgulas, listas e separadores; não edite fragmentos manualmente no CSV.
Could not construct all features expected	Podem faltar dados espaciais em todos os remates, ou existir incompatibilidade entre funções e modelo. Use a mesma versão e registos espaciais válidos.
The events DataFrame index must be unique	Na interface Python, o índice está repetido. Se for apenas um índice de linhas, pode usar events.reset_index(drop=True); preserve os identificadores reais em colunas.
ModuleNotFoundError ou modelo não encontrado	Abra o terminal na pasta principal, ative o ambiente e confirme utils, dependências e models/pipeline.joblib.

Sinal ou mensagem	Causa provável e ação
The model artifact has no feature_names_in_	Pode ter sido guardado apenas o classificador. É necessária a pipeline final completa. A exportação cabe ao responsável técnico.
Resultados inesperados sem mensagem de erro	Reveja coordenadas, orientação, equipa relativa, guarda-redes, categorias e cobertura espacial. O script não valida toda a semântica dos dados.

Valores em falta e posições incompletas

Uma coluna em falta gera erro; um valor em falta dentro de uma coluna pode ter outro tratamento. Nos seis indicadores binários, é convertido em False. A parte do corpo omissa passa a Other e a técnica omissa também passa a Other. Um passe-chave omisso produz remate não assistido. Uma localização omissa num remate elegível gera erro.

Se todos os remates elegíveis estiverem sem freeze frame, podem faltar variáveis e a execução falha. Num lote misto, alguns remates podem receber previsão apesar de faltarem descritores espaciais. Uma lista vazia conta como observação sem jogadores: produz contagens zero e distâncias omissas. Não a use para representar dados desconhecidos. A falta do guarda-redes produz valores omissos nas suas seis variáveis. Para aplicação comparável ao treino, prefira registos completos e reveja os casos incompletos.

11. O que foi analisado e concluído

Percurso da análise no notebook

O notebook.ipynb começa pela exploração dos eventos e dos remates, compara origens de posse e fases de bola parada e delimita a amostra de primeira fase após cantos e livres indiretos. A exploração identificou maior concentração de golos em zonas centrais e próximas da baliza. Foram construídos descritores de geometria, oposição e contexto, agrupadas técnicas raras e codificadas categorias, originando 46 variáveis.

A amostra final incluiu 3 685 remates e 321 golos, cerca de 8,71% de conversão. Aproximadamente 70% dos remates tiveram origem em cantos e 30% em livres indiretos. Os dados foram divididos aleatoriamente em desenvolvimento (80%) e teste (20%), com proporções semelhantes de golos. O teste reuniu 737 remates e 64 golos.

Foram comparados regressão logística Elastic Net, Random Forest, HistGradientBoosting e XGBoost. A pesquisa bayesiana usou validação cruzada estratificada, com seleção de variáveis integrada no ajuste. A seleção combinou eliminação recursiva e seleção sequencial nos dois sentidos. O HistGradientBoosting apresentou a menor perda logarítmica de desenvolvimento e reteve 15 variáveis.

Resultados no teste

Indicador	Modelo especializado	StatsBomb
Perda logarítmica	0,254819	0,257461
Brier score	0,069731	0,069721
ROC AUC	0,747365	0,742060
Precisão média	0,311920	0,316505
Total de xG para 64 golos	60,79	63,02

Nas duas primeiras métricas, menor é melhor; nas duas seguintes, maior é melhor. O modelo especializado obteve ligeira vantagem em perda logarítmica e ROC-AUC. A StatsBomb obteve ligeira vantagem em Brier score e precisão média e um total de xG mais próximo dos golos observados. Nenhum dos dois foi melhor em todos os critérios.

O que os resultados permitem concluir

As diferenças foram avaliadas com 5 000 reamostragens emparelhadas. Todos os intervalos de confiança de 95% das diferenças entre o modelo escolhido e a StatsBomb incluíram zero. Isto não demonstra superioridade nem equivalência estatística: indica que a amostra não permitiu distinguir claramente os desempenhos. O resultado apoia a viabilidade da especialização, com qualidade preditiva próxima da referência nos remates avaliados.

A análise SHAP destacou o ângulo de baliza desobstruído, a distância ao centro da baliza e a distância do guarda-redes à bola. Estas são associações aprendidas, não efeitos causais nem instruções táticas automáticas. O declive de calibração do modelo foi próximo de 1, mas a StatsBomb apresentou menor erro de calibração esperado. A calibração não deve ser resumida por um único indicador.

Limites para a utilização

O modelo foi desenvolvido numa única competição, com uma amostra reduzida e apenas 64 golos no teste. A divisão aleatória não separa necessariamente jogos, equipas ou rotinas entre treino e teste. Não existe validação externa que garanta resultados semelhantes noutras competições, épocas ou fornecedores. Os registos espaciais representam apenas o instante da finalização e não todo o desenvolvimento da rotina.

Os próximos passos prioritários são aumentar e diversificar os dados, validar por jogo e por época, testar competições externas, rever a identificação das fases e comparar versões simplificadas do modelo. Até essas verificações, utilize os valores como apoio à análise dentro do âmbito definido e explicite as limitações ao comunicar resultados.