Modelo de Golos Esperados para Bolas Paradas no Futebol

Relatório do Projeto

Desenvolvimento e Avaliação de um Modelo de xG

Introdução

No futebol, avaliar uma oportunidade de golo apenas pelo número de remates pode esconder diferenças importantes na qualidade das situações criadas. Um remate de longa distância, com vários defesas pela frente, não representa o mesmo perigo que uma finalização próxima da baliza e sem oposição. É neste contexto que surge o xG, ou golos esperados, uma métrica que permite estimar a probabilidade de um remate resultar em golo a partir das suas características.

Nas bolas paradas, esta análise ganha um contexto próprio. A concentração de jogadores junto da baliza, o posicionamento do guarda-redes e a obstrução da trajetória podem alterar a dificuldade da finalização. Posto isto, o desafio deste projeto consiste em desenvolver um modelo de xG dedicado aos remates da primeira fase de sequências iniciadas por cantos e livres indiretos, procurando compreender se uma abordagem especializada consegue obter resultados competitivos face ao indicador da StatsBomb.

O xG é interpretado como uma probabilidade condicional de golo. Um valor de 0,10 corresponde a uma probabilidade estimada de 10% para um remate com as características observadas. A soma destas probabilidades permite resumir a qualidade das oportunidades de um conjunto de remates; não constitui uma previsão determinística do resultado de um jogo.

Para tal, o trabalho percorre as várias etapas do processo analítico, desde a caracterização da amostra e preparação dos dados até à seleção e avaliação dos modelos. Posteriormente, são analisadas a calibração das probabilidades e a importância das variáveis nas previsões. A discussão relaciona os resultados com o objetivo do estudo, identifica as limitações da abordagem e apresenta possibilidades de desenvolvimento futuro.

Objetivos do projeto

Este trabalho tem como objetivos definir o conjunto de remates a estudar, representar o contexto de cada finalização através de variáveis espaciais e comparar diferentes algoritmos de aprendizagem automática. Para além disso, pretende-se avaliar o modelo escolhido face ao xG da StatsBomb, perceber quais os fatores com maior influência nas previsões e identificar os próximos passos necessários para melhorar a sua fiabilidade.

Metodologia

Dados e definição da amostra

Foram utilizados dados de eventos e de posicionamento dos jogadores no instante do remate, provenientes da StatsBomb e relativos à Primeira Liga portuguesa nas épocas 2023/2024, 2024/2025 e 2025/2026. O conjunto inicial compreendia 2 997 912 eventos e 161 atributos. Destes eventos, 22 606 correspondiam a remates, constituindo o ponto de partida para a definição da população em estudo.

A amostra foi limitada aos remates da primeira fase de posses iniciadas por cantos ou livres indiretos. Para isso, foram selecionados os eventos de remate associados a estas origens de posse, classificados como finalizações em jogo corrido e identificados como pertencentes à primeira fase. A classificação da execução em jogo corrido não contradiz a origem da posse numa bola parada: distingue o remate

de um livre direto, penálti ou canto direto. Foram excluídos os lançamentos laterais e as situações de segunda fase.

A escolha da primeira fase procurou aproximar a finalização da rotina inicialmente preparada e reduzir a heterogeneidade das situações analisadas. Remates após alívios ou reorganizações posteriores podem depender de processos diferentes dos que orientam a execução inicial. A identificação da fase baseou-se na classificação disponível nos dados, sem reconstrução independente de toda a sequência. Após a filtragem, foram retidos 3 685 remates: 2 581 após cantos e 1 104 após livres indiretos.

Variáveis e preparação

O problema foi formulado como uma tarefa de classificação binária com produção de probabilidades. A variável alvo assumiu o valor 1 nos remates que resultaram em golo e 0 nos restantes. Foram excluídos dos preditores os atributos que revelavam o desfecho do remate ou incorporavam estimativas prévias da sua qualidade. Esta exclusão procurou evitar a fuga de informação (data leakage), que ocorre quando o modelo utiliza informação sobre o resultado que pretende prever, ou informação que não estaria disponível no momento da previsão, produzindo uma avaliação artificialmente favorável do desempenho. As variáveis identificativas, como o jogador e a equipa, foram igualmente removidas para reduzir o risco de enviesamentos associados a identidades específicas e centrar a previsão nas características da oportunidade. O marcador e as variáveis temporais também não integraram o modelo. Por fim, o xG da StatsBomb foi excluído dos preditores e reservado como indicador de referência para comparar o desempenho dos modelos.

Nas variáveis binárias, os valores em falta foram tratados como «não». Por exemplo, sem registo sobre um remate de primeira, considerou-se que este não tinha sido executado de primeira. Assumiu-se, assim, que a falta de registo correspondia à ausência da característica. Criou-se também um indicador de assistência pela existência de um passe-chave. As técnicas normal, vólei e meio-vólei foram mantidas, agrupando-se as restantes numa categoria residual. Aplicou-se one-hot encoding à técnica e à parte do corpo: cada categoria originou um indicador com valor 1 quando presente e 0 caso contrário, sem ordem artificial entre categorias. Obtiveram-se 46 preditores.

A distribuição da resposta foi mantida, sem equilibrar artificialmente o número de golos e não golos. O objetivo era estimar probabilidades compatíveis com a frequência de golo da população estudada, e não maximizar o número de previsões binárias corretas. A interpretação do desempenho centrou-se, por isso, nas probabilidades produzidas, em vez de aplicar um limiar fixo de 0,5.

Representação espacial

As posições dos jogadores e do rematador, originalmente num referencial de 120 × 80 unidades, foram convertidas para um campo de 105 × 68 metros para calcular os descritores geométricos. Foram consideradas as distâncias à baliza e ao seu centro, a proximidade dos jogadores, as contagens de colegas e adversários em raios de 1, 3 e 5 metros e a ocupação do triângulo formado pelo rematador e pelos postes. Foram ainda calculados ângulos de baliza disponíveis e obstruídos, bem como medidas do posicionamento e cobertura angular do guarda-redes.

A obstrução angular foi aproximada através de uma representação circular dos jogadores, com raios de 0,35 metros para os defesas e 0,50 metros para o guarda-redes. Estes valores constituem pressupostos simplificadores. A geometria adotada para os postes produz, após a conversão de

coordenadas, uma largura de baliza de 6,8 metros. Esta escolha afeta os ângulos estimados e deve ser considerada na interpretação e revisão dos descritores espaciais.

Divisão dos dados e seleção do modelo

Os dados foram divididos aleatoriamente em duas partições, com estratificação pela variável alvo: 80% para desenvolvimento e 20% para teste. Foi utilizada a semente aleatória 21 para permitir a reprodução da divisão. O desenvolvimento incluiu 2 948 remates e 257 golos; o teste reuniu 737 remates e 64 golos. A estratificação manteve proporções de golo próximas nas duas partições, enquanto a separação do teste permitiu avaliar o desempenho em observações não utilizadas no ajuste dos candidatos.

Foram comparadas quatro famílias de modelos: regressão logística com regularização Elastic Net, Random Forest, HistGradientBoosting e XGBoost. A regressão logística forneceu uma alternativa regularizada mais simples, enquanto os métodos de árvores permitiram representar relações não lineares e interações. A otimização dos hiperparâmetros utilizou pesquisa bayesiana com 20 iterações e validação cruzada estratificada de cinco grupos no conjunto de desenvolvimento. A perda logarítmica foi o critério principal de seleção, por avaliar diretamente a qualidade das probabilidades.

O pré-processamento e a seleção das variáveis foram integrados no processo de ajuste de cada modelo. Na regressão logística, as variáveis numéricas foram imputadas pela mediana e normalizadas, com indicadores adicionais de ausência. Os modelos de árvores considerados mantiveram os valores omissos, recorrendo à sua capacidade de os tratar durante o ajuste. Nos procedimentos dependentes dos dados, o ajuste foi realizado dentro das partições de treino da validação cruzada, reduzindo a transmissão de informação das partições de validação para o processo de seleção.

A seleção das variáveis não fica dependente de um único método. Para tal, são combinados três procedimentos: eliminação recursiva com validação cruzada, seleção sequencial progressiva e seleção sequencial regressiva. Uma variável é mantida quando recebe pelo menos dois votos. Se uma variável binária completa receber apenas um voto, pode ainda ser recuperada através de um teste do qui-quadrado com $p<0,05$. A validação interna do seletor usa três grupos. É importante salientar que esta regra serve para selecionar variáveis, não para confirmar estatisticamente a importância de cada uma.

Avaliação e incerteza

O xG da StatsBomb foi utilizado como termo de comparação para avaliar se a especialização em bolas paradas acrescentava valor preditivo. As suas probabilidades foram avaliadas nos mesmos 737 remates do conjunto de teste e com as mesmas métricas dos modelos desenvolvidos, permitindo uma comparação direta. A avaliação distinguiu qualidade probabilística, discriminação e calibração. A perda logarítmica penaliza probabilidades atribuídas incorretamente, sobretudo previsões muito confiantes; o Brier score mede o erro quadrático entre a probabilidade estimada e o desfecho observado. Em ambas, valores inferiores são preferíveis. A ROC-AUC avalia a ordenação de golos face a não golos, enquanto a precisão média resume a relação entre precisão e sensibilidade, sendo particularmente relevante perante a baixa prevalência de golo. Nestas duas métricas, valores superiores são preferíveis.

A calibração foi analisada através de curvas, erro de calibração esperado, interceto e declive. Foram igualmente comparadas a probabilidade média, a frequência observada de golo e a soma dos golos esperados. O erro de calibração esperado foi calculado com oito grupos. Para quantificar a incerteza,

utilizou-se bootstrap emparelhado com 5 000 reamostragens, semente 21 e intervalos percentis de 95%. Golos e não golos foram reamostrados separadamente, preservando as respetivas contagens, e os mesmos índices foram aplicados a todos os modelos para comparar as suas diferenças.

Ajuste final e interpretação

Após a avaliação, o modelo final foi ajustado aos 3 685 remates, mantendo os 15 preditores selecionados no desenvolvimento. Foram também obtidas previsões por validação cruzada estratificada de cinco grupos, em que cada remate foi avaliado por um classificador ajustado sem essa observação, com as variáveis e os hiperparâmetros já fixados. A interpretação do ajuste final recorreu a valores SHAP, que decompõem a previsão em contribuições associadas às variáveis. Estas contribuições descrevem o comportamento do modelo, sem estabelecer relações causais.

Resultados

Caracterização e seleção

A amostra final inclui 321 golos em 3 685 remates, correspondendo a uma taxa de conversão de 8,71%. Os cantos representam cerca de 70% dos remates e os livres indiretos os restantes 30%. A taxa observada no teste é de 8,68%. Estas dimensões condicionam sobretudo a avaliação de configurações raras e de probabilidades elevadas.

Na análise exploratória, os golos concentraram-se em posições mais próximas e centrais relativamente à baliza, enquanto os remates sem golo apresentaram maior dispersão. A altura do remate mostrou distribuições semelhantes nos dois desfechos. A cabeça e o pé direito foram as partes do corpo mais frequentes; as diferenças de conversão entre cabeça, pé esquerdo e pé direito foram reduzidas. As categorias raras apresentaram estimativas menos estáveis, o que motivou a agregação de técnicas de remate pouco representadas.

O HistGradientBoosting apresentou a menor perda logarítmica na validação cruzada de desenvolvimento, com 0,254478, sendo selecionado como modelo principal. Como se observa na Tabela 1, os métodos de árvores tiveram resultados próximos, enquanto a regressão logística apresentou uma perda ligeiramente superior. O modelo selecionado reteve 15 das 46 variáveis iniciais. Estas estimativas orientaram a seleção; a avaliação no teste reservado permitiu examinar posteriormente a sua generalização.

Modelo	Perda logarítmica	Variáveis retidas
HistGradientBoosting	0,254478	15
Random Forest	0,255397	27
XGBoost	0,255651	21
Regressão logística Elastic Net	0,257724	23

Tabela 1: Comparação na validação cruzada de desenvolvimento

A configuração selecionada utilizou uma taxa de aprendizagem de 0,01 e 700 iterações de boosting. As árvores foram limitadas a uma profundidade máxima de 2 e a um máximo de 7 folhas, com pelo menos 40 observações por folha. Foi ainda aplicada regularização L2 de intensidade 20. Esta

combinação restringiu a complexidade de cada árvore e a amplitude do ajuste, procurando controlar o sobreajustamento numa amostra de dimensão reduzida.

As 15 variáveis selecionadas abrangeram três dimensões. O contexto da finalização incluiu meio-vólei, outras técnicas, remate de primeira, situação de um para um, baliza aberta, duelo aéreo ganho e remate assistido. A geometria do remate e a oposição defensiva foram representadas pela distância à baliza, distância ao seu centro, distância ao segundo defesa mais próximo, número de defesas num raio de 3 metros, número de defesas num raio de 5 metros e ângulo de baliza desobstruído. Por fim, foram mantidas a distância do guarda-redes à bola e a sua cobertura angular da baliza.

Desempenho no conjunto de teste

Modelo	Log loss	Brier	ROC AUC	Precisão média
HistGradientBoosting	0,254819	0,069731	0,747365	0,311920
XGBoost	0,255691	0,069888	0,746448	0,307269
Random Forest	0,256323	0,070138	0,741526	0,303694
Logística Elastic Net	0,259354	0,071075	0,733934	0,298232
StatsBomb	0,257461	0,069721	0,742060	0,316505

Tabela 2: Métricas nos 737 remates do conjunto de teste

Entre os modelos desenvolvidos, o HistGradientBoosting apresenta os melhores valores pontuais nas quatro métricas. Face à StatsBomb, reduz a perda logarítmica em cerca de 1,03% e aumenta a ROC-AUC em 0,005305. A StatsBomb obtém, em contrapartida, um Brier score ligeiramente inferior e uma precisão média superior. Não existe, portanto, domínio de um dos modelos em todas as dimensões.

A perda logarítmica do HistGradientBoosting passa de 0,238199 no treino para 0,254819 no teste. No XGBoost, a passagem é de 0,223882 para 0,255691. A maior diferença no XGBoost é compatível com maior ajustamento específico ao treino, embora a comparação entre previsões de treino e teste não constitua, por si só, uma quantificação isolada do sobreajustamento.

Incerteza e calibração

Todos os intervalos das diferenças entre StatsBomb e HistGradientBoosting incluem zero. O intervalo de 95% da perda logarítmica do HistGradientBoosting é [0,232909; 0,276523], e o da ROC-AUC é [0,675017; 0,815720]. A Tabela 3 apresenta diretamente a incerteza das diferenças emparelhadas, mais relevante para a comparação do que a simples sobreposição de intervalos individuais.

Métrica	Diferença	Intervalo de 95%
Perda logarítmica	+0,002641	[−0,008888; 0,014888]
Brier score	−0,000010	[−0,003634; 0,003640]
ROC AUC	−0,005305	[−0,036950; 0,023543]
Precisão média	+0,004585	[−0,059496; 0,073809]

Tabela 3: Diferenças StatsBomb menos HistGradientBoosting

Tendo em conta estes intervalos, não é possível concluir que um dos modelos seja superior ao outro. Porém, a inclusão de zero não permite afirmar que os modelos sejam estatisticamente equivalentes, pois essa conclusão exigiria um procedimento próprio e margens de equivalência definidas previamente. Assim, a leitura mais prudente é que os resultados observados são próximos, mas continuam sujeitos a uma incerteza relevante.

Indicador	HistGradientBoosting	StatsBomb
Interceto de calibração	0,064499	−0,191480
Declive de calibração	1,000472	0,898983
ECE com oito grupos	0,018148	0,010128
Probabilidade média	0,082480	0,085510
Total de xG	60,787750	63,020848
Golos observados	64	64

Tabela 4: Calibração e total de golos esperados no teste

O declive do HistGradientBoosting foi próximo do valor ideal de 1, mas a StatsBomb apresentou menor erro de calibração esperado e um total de xG mais próximo dos 64 golos observados. O modelo especializado subestimou esse total em cerca de 3,21 golos, face a 0,98 na StatsBomb. Assim, um declive próximo de 1 não se traduziu automaticamente numa melhor calibração em todos os indicadores. Não foram calculados intervalos de confiança para estas estimativas de calibração.

Interpretação do modelo

A análise SHAP identificou o ângulo de baliza desobstruído como a variável de maior importância global, seguido da distância do remate ao centro da baliza e da distância do guarda-redes à bola. Ângulos disponíveis mais amplos e remates mais próximos da baliza associaram-se, em geral, a previsões superiores. As situações de duelo aéreo ganho, a distância ao segundo defesa mais próximo e a existência de assistência surgiram num segundo nível de influência.

A distância do guarda-redes à bola revelou uma relação estreita com a distância do próprio remate à baliza. Por isso, a sua contribuição não deve ser interpretada como um efeito independente do posicionamento do guarda-redes. A importância global foi medida pela média dos valores absolutos das contribuições SHAP na escala de saída bruta do modelo, aproximadamente em logaritmos das possibilidades de golo. Estas magnitudes não correspondem diretamente a pontos percentuais de probabilidade.

A seleção e a importância final das variáveis não foram coincidentes. Algumas características mantidas, como o remate de primeira, a situação de um para um e a categoria residual de técnica, apresentaram contribuições SHAP próximas de zero. Isto indica que a presença de uma variável no conjunto selecionado não garante uma influência elevada nas previsões do modelo final.

Discussão

Significado dos resultados

Refletindo sobre os resultados apresentados, é possível afirmar que o desenvolvimento de um modelo especializado para remates de primeira fase após cantos e livres indiretos é viável. As variáveis espaciais parecem ajudar a representar a qualidade das oportunidades. No entanto, a proximidade aos resultados da StatsBomb não significa que a especialização tenha uma vantagem comprovada: as diferenças são pequenas, os intervalos são amplos e nenhuma das abordagens apresenta os melhores valores em todas as métricas.

A calibração ilustra a necessidade de interpretar vários indicadores em conjunto. O declive do modelo especializado sugere uma dispersão global das probabilidades próxima da desejável, mas a subestimação do total de golos e o maior erro de calibração esperado mostram limitações que esse declive, isoladamente, não revela. Para uma métrica destinada a somar probabilidades e comparar oportunidades, estes desvios são relevantes mesmo quando a capacidade de ordenação é semelhante.

Para compreender melhor o contributo das variáveis espaciais, seria importante comparar o modelo completo com versões mais simples. Por exemplo, um modelo baseado apenas na localização, distância e ângulo permitiria perceber se a informação dos defesas e do guarda-redes melhora efetivamente as previsões. A análise SHAP mostra como o modelo utiliza as variáveis, mas não substitui esta comparação.

Limitações da validação

A amostra está concentrada numa única competição e inclui apenas 64 golos no teste. A divisão aleatória pode distribuir remates do mesmo jogo, equipa ou rotina por treino e teste. A validação cruzada não elimina esta dependência, e o bootstrap por remate não representa a correlação ao nível do jogo. A estratificação do bootstrap fixa também a prevalência observada, pelo que os intervalos não abrangem toda a incerteza associada à variação da taxa de golo entre contextos.

O conjunto de teste é usado para apresentar métricas de todos os candidatos e várias análises comparativas. A seleção pelo critério de validação cruzada deve permanecer congelada antes dessa consulta. Se decisões posteriores forem orientadas pelos resultados de teste, será necessário um novo conjunto independente para a avaliação final.

As previsões obtidas por validação cruzada com o conjunto final de variáveis não representam uma avaliação aninhada de todo o processo de seleção, pois as variáveis e os hiperparâmetros foram previamente escolhidos no desenvolvimento. Esta distinção é relevante: excluir uma observação do ajuste do classificador não equivale a excluí-la de todas as decisões anteriores. A análise SHAP incidiu também no modelo ajustado à amostra completa, devendo a estabilidade das relações identificadas ser examinada em dados independentes.

Dados espaciais e utilização prática

Os registos espaciais representam o instante do remate, sem caracterizar integralmente o desenvolvimento da rotina, a movimentação anterior, os bloqueios ou a qualidade da entrega. Além disso, interpretar valores binários omissos como ausência do fenómeno pode confundir falta de registo com uma situação efetivamente inexistente. A informação espacial incompleta e os pressupostos sobre as dimensões dos jogadores e da baliza introduzem outras fontes de incerteza.

A definição da população também requer revisão. Embora os livres diretos tenham sido excluídos, a utilização das etiquetas de origem da posse e de fase pode permitir a inclusão de remates após livres diretos falhados, que não correspondem necessariamente à rotina indireta pretendida. A verificação das sequências, incluindo ressaltos e desvios, permitiria tornar os critérios de inclusão mais consistentes. Em paralelo, a qualidade e a cobertura dos registos espaciais devem ser avaliadas antes de aplicar o modelo a novas amostras.

O xG obtido avalia a qualidade dos remates observados. Não mede, isoladamente, a eficácia integral de uma rotina, pois ignora bolas paradas que não originam remate. Uma aplicação ao treino deve combinar este indicador com frequência de finalização, recuperação de segundas bolas e outros resultados da sequência.

Conclusão

Este trabalho permitiu desenvolver e avaliar um modelo de xG dedicado aos remates da primeira fase de cantos e livres indiretos. A partir de 3 685 observações, foram construídas 46 variáveis e selecionado um modelo HistGradientBoosting com 15 preditores. A abordagem combinou informação contextual e espacial, seleção de variáveis e otimização de hiperparâmetros, sendo avaliada num conjunto de teste reservado e comparada com o xG da StatsBomb.

No teste, o modelo alcança perda logarítmica de 0,254819, Brier score de 0,069731, ROC-AUC de 0,747365 e precisão média de 0,311920. Estes resultados são próximos dos da StatsBomb. A ligeira vantagem em perda logarítmica e ROC-AUC não é acompanhada de superioridade em todas as métricas, e os intervalos emparelhados não permitem concluir que exista uma melhoria consistente.

O principal contributo deste projeto é mostrar que uma abordagem especializada consegue alcançar resultados competitivos num conjunto de remates bem definido. A abertura angular disponível, a distância à baliza e a relação espacial com o guarda-redes destacam-se nas previsões. Contudo, a importância destas variáveis para o modelo não demonstra uma relação de causa e efeito, nem garante que os mesmos padrões se mantenham noutras épocas ou competições.

O desenvolvimento seguinte deve privilegiar a expansão da amostra, a auditoria das etiquetas de fase e da geometria, e a validação por jogo, temporal e externa. Recomenda-se reservar uma época futura sem qualquer utilização na seleção, estimar a incerteza por grupos de jogos e comparar o modelo completo com versões simplificadas. A incorporação dos eventos anteriores ao remate deverá ser avaliada pelo respetivo ganho incremental.

Para concluir, esta primeira versão constitui um ponto de partida para o desenvolvimento de um modelo de xG dedicado às bolas paradas. Os resultados justificam a continuação do estudo, mas a existência de mais dados e de uma validação mais exigente será essencial para perceber se o desempenho se mantém em novos contextos. Só depois dessas etapas será possível avaliar com maior confiança o valor acrescentado desta especialização.